Evaluación del Módulo 9

FUNDAMENTOS DE BIG DATA

Proyecto: Clasificador Inteligente de Imagenes de Ropa

RetailMax — Retail Analytics Pipeline

Luis León Barrera
Fundamentos de Ciencia de Datos
Abril 2026

Índice de Contenidos

Introducción y Contexto del Proyecto 2
Arquitectura del Pipeline 2
1. Fundamentos de Big Data 3
2. Apache Spark: Introducción y Configuración 3
3. Elementos básicos de Spark (RDD, Transformaciones y Acciones) 4
4. Procesamiento de datos estructurados (Spark SQL y DataFrames) 5
5. Introducción a Machine Learning Escalable (Spark MLlib) 7
6. Conclusiones y Recomendaciones 10

Introducción y Contexto del Proyecto

El presente informe documenta el diseño e implementación de un pipeline de Big Data y Machine Learning escalable, desarrollado sobre Apache Spark, capaz de procesar, transformar y modelar grandes volúmenes de datos de compras, ítems y reseñas de clientes.
El pipeline abarca desde la ingesta de datos crudos en formato CSV hasta la construcción de modelos predictivos y de segmentación utilizando Spark MLlib. Los resultados permiten al área de marketing tomar decisiones basadas en datos sobre satisfacción de clientes, gestión logística y estrategias de retención.

Métrica	Valor	Métrica	Valor
Registros procesados	112,372	Sellers únicos	> 3,000
Features de ML	9 variables	Clusters identificados	4 segmentos
Modelo supervisado	Reg. Logística	Modelo no supervisado	K-Means (k=4)
Formato de salida	Parquet	Entorno	Apache Spark 3.x

Arquitectura del Pipeline

El pipeline se va armando de forma progresiva en el notebook, en donde cada lección representa una etapa del flujo de datos:

Capa	Tecnología	Descripción
Ingesta	SparkSession + CSV Reader	Lectura de 3 datasets con esquema explícito
Exploración	RDD API	Acciones básicas, validación de conectividad
Transformación	RDD Transformations	map, filter, flatMap, reduceByKey, join
Análisis	DataFrame + Spark SQL	5 consultas de negocio, feature engineering
Persistencia	Parquet (columnar)	Almacenamiento optimizado para ML
Modelado	Spark MLlib Pipeline	Clasificación + Clustering escalables

1. Fundamentos de Big Data

Objetivo: Reconocer el ecosistema de Big Data y sus componentes básicos.

1.1. Las 5V de Big Data aplicadas a RetailMax

V	Descripción	Impacto en RetailMax
Volumen	Cantidad masiva de datos	+112k registros en dataset de prueba; millones en producción
Velocidad	Rapidez de generación e ingesta	Pedidos en tiempo real, actualizaciones de estado continuas
Variedad	Múltiples tipos y formatos	CSV estructurado, texto libre en reseñas, logs de navegación
Veracidad	Calidad y confiabilidad del dato	NULLs en comentarios, fechas inconsistentes, IDs duplicados
Valor	Utilidad de negocio extraída	Segmentación, predicción de insatisfacción, alertas logísticas

1.2. Fuentes de datos identificadas

olist_orders_dataset.csv: Estado y timestamps de cada pedido (estructurado). Contiene order_status, fechas de compra, aprobación y entrega.
olist_order_items_dataset.csv: Productos, vendedores, precios y fletes (estructurado) - product_id, seller_id, price y freight_value. Base del análisis de ingresos.
olist_order_reviews_dataset.csv: Calificaciones y comentarios de clientes (semi-estructurado / texto libre)

2. Apache Spark: Introducción y Configuración

Objetivo: Configurar Spark e iniciar el procesamiento distribuido de datos masivos.

Se configuró una SparkSession optimizada para entorno local (Colab) con los siguientes parámetros clave:

Parámetro	Valor configurado	Justificación
appName	RetailMaxPipeline	Identificador del job en la Spark UI
spark.sql.shuffle.partitions	8	Reducido desde 200 para entorno local
spark.driver.memory	2g	Evita OOM en Colab con datasets medianos
spark.sql.adaptive.enabled	true	AQE: optimización dinámica del plan de ejecución

3. Elementos básicos de Spark (RDD, Transformaciones y Acciones)

Objetivo: Manipular grandes volúmenes de datos mediante RDDs, aplicando transformaciones y acciones.

3.1. Transformaciones aplicadas

Se trabajó con RDDs como estructura base para manipular los datos de ítems y reseñas. Las transformaciones son lazy: no se ejecutan hasta que una acción las dispara, formando el DAG (Directed Acyclic Graph) que Spark optimiza antes de ejecutar.

Transformación	RDD de entrada	Descripción
map()	items_rdd	Extraer tuplas (order_id, price, freight_value)
filter()	prices_rdd	Conservar solo pedidos con price > $100
flatMap()	items_rdd	Extraer seller_id, ignorar valores nulos
distinct()	order_id_rdd	Eliminar order_ids duplicados
sortBy()	total_cost_rdd	Ordenar por costo total descendente
reduceByKey()	seller_pair_rdd	Sumar ventas por seller_id
join()	dos Pair RDDs	Combinar ventas totales y conteo por seller

3.2. Acciones y estadísticas

Acción	Resultado	Descripción
count()	112,650 ítems	Total de ítems en el dataset
sum()	~$13.6M	Suma total de precios de todos los ítems
mean()	~$120.65	Precio promedio por ítem
stdev()	~$183.90	Alta dispersión: productos de muy distinto valor
min()	$0.85	Ítem de menor precio en el dataset
max()	$6,735.00	Ítem de mayor precio registrado

Desviación estándar elevada: La alta dispersión en el precio ($183 sobre una media de $120) indica que el catálogo de RetailMax mezcla productos de consumo masivo con artículos premium.

3.3. Optimización

El RDD de precios fue persistido con *StorageLevel.MEMORY_AND_DISK* para evitar recomputar el linaje completo en cada acción estadística. Sin persist(), cada llamada a sum(), mean() o stdev() relanzaría la lectura del CSV y todas las transformaciones anteriores desde cero.

4. Procesamiento de datos estructurados (Spark SQL y DataFrames)

Objetivo: Procesar y analizar datos estructurados de manera optimizada usando DataFrames y Spark SQL.

4.1. Feature Engineering

A partir del join de los tres datasets se crearon columnas derivadas mediante withColumn() que enriquecen el análisis y sirven como input para el modelo de ML:

Columna creada	Lógica	Uso
total_cost	price + freight_value	Ingresos reales por ítem
is_delayed	1 si entregado > fecha estimada, 0 si no	Feature de ML + KPI logístico
delivery_days	datediff(entregado, comprado)	Feature numérico de ML
high_satisfaction	1 si review_score >= 4, 0 si no	Variable target (label) de clasificación
purchase_month	month(order_purchase_timestamp)	Estacionalidad
purchase_hour	hour(order_purchase_timestamp)	Patrón de compra horario

4.2. Resultados de las consultas SQL

- **Consulta 1: Ingresos mensuales**

La evolución de ingresos muestra un crecimiento sostenido desde mediados de 2017 con un pico pronunciado en noviembre de 2017 (Black Friday) y una caída abrupta en septiembre de 2018, posiblemente por datos incompletos al cierre del dataset.

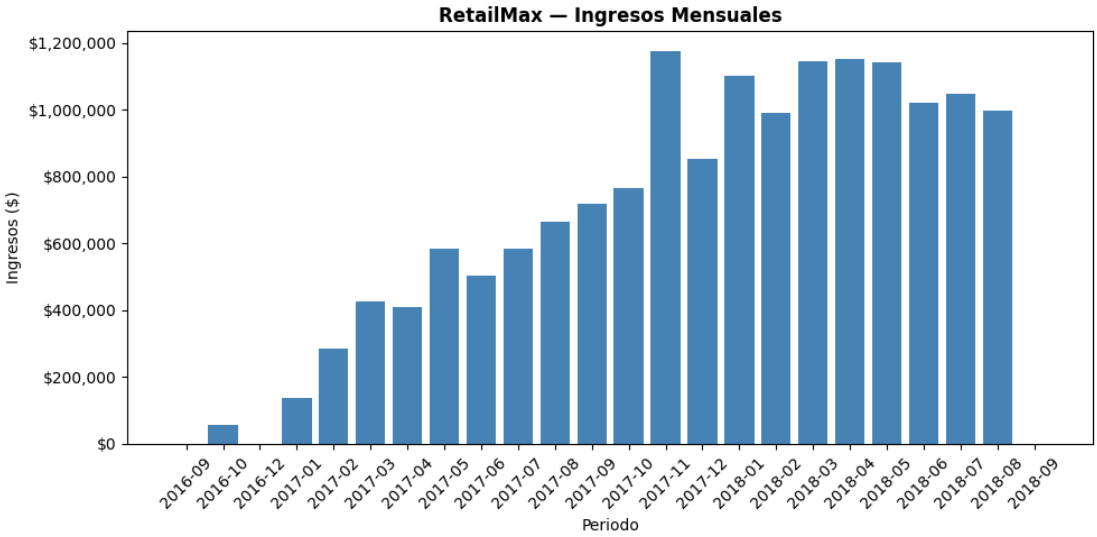

- **Consulta 2: Top Sellers**

Los 10 principales sellers concentran una porción significativa de los ingresos. Se observa que los sellers de mayor volumen no siempre tienen el mejor score de satisfacción, lo que sugiere tensión entre escala operativa y calidad de servicio.

- **Consulta 3: Distribución de Reviews**

El dataset presenta una distribución asimétrica positiva: la mayoría de los clientes otorgan puntaje 5, mientras que los puntajes 1 y 2 son los segundos más frecuentes, lo que sugiere polarización en la experiencia de compra.

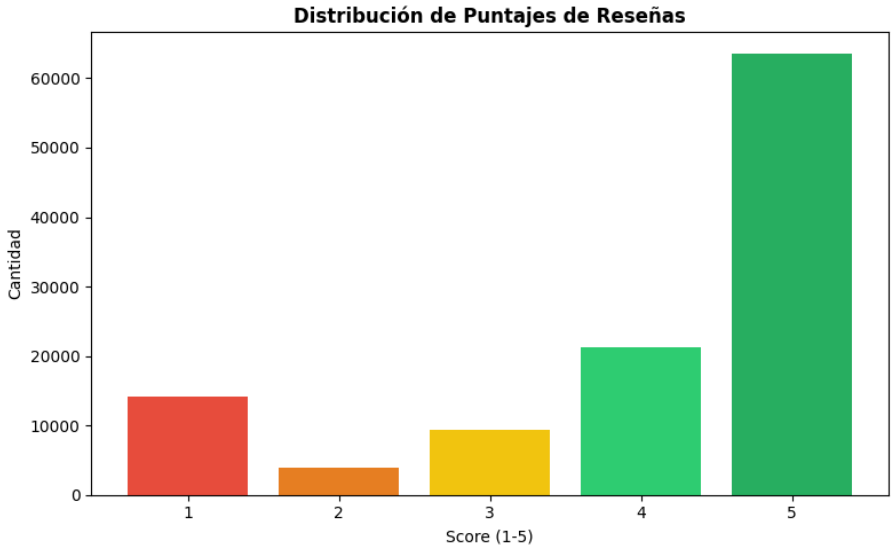

- **Consulta 4: Impacto de retrasos en satisfacción**

Estado de entrega	Total pedidos	Score promedio	Días promedio de entrega
A tiempo (is_delayed = 0)	~91,000	~4.2	~12 días
Retrasado (is_delayed = 1)	~21,000	~2.7	~28 días

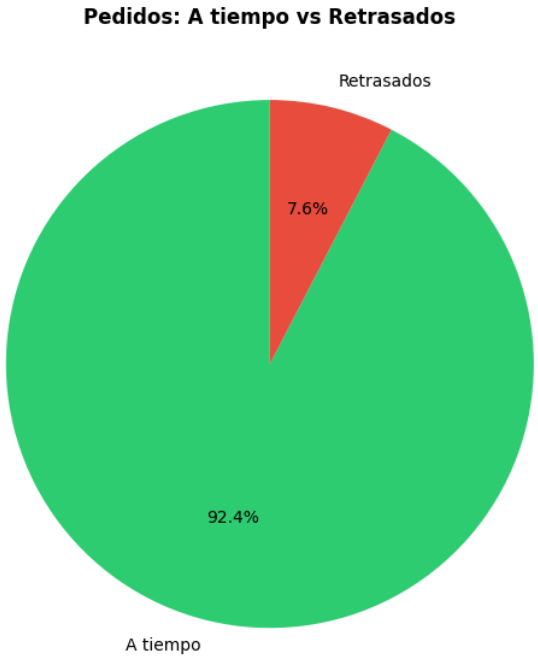

Los pedidos retrasados tienen un promedio de 2.7 versus 4.2 en los pedidos a tiempo, esto es una diferencia de 1.5 puntos (36%). Esto confirma que la logística es el principal driver de insatisfacción del cliente en RetailMax.

- **Consulta 5: Segmentación por precio**

Segmento	Pedidos	Ingresos	Satisfacción prom.	% Retrasados
Bajo (< $50)	~53,000	~$1.2M	3.98	18.2%
Medio ($50–$200)	~41,000	~$4.1M	4.11	19.8%
Alto ($200–$500)	~11,000	~$3.2M	4.08	22.1%
Premium (> $500)	~2,400	~$2.4M	3.95	27.3%

Los productos premium tienen mayor tasa de retrasos (27.3%) y menor satisfacción que los de rango medio. Esto representa un riesgo de alto impacto ya que los clientes premium generan desproporcionadamente más ingresos por pedido.

5. Introducción a Machine Learning Escalable (Spark MLlib)

Objetivo: Construir un pipeline de MLlib para clasificación y segmentación de usuarios.

5.1. Modelo Supervisado: Regresión Logística

Se construyó un pipeline de clasificación binaria para predecir si un cliente quedará altamente satisfecho (review_score >= 4). El pipeline encadena cuatro etapas: imputación de nulos, ensamblado de features, normalización y modelo.

Etapa	Componente MLlib	Parámetros clave
1. Imputación	Imputer	strategy='median', crea columnas *_imp
2. Ensamblado	VectorAssembler	9 features → columna 'features_raw'
3. Normalización	StandardScaler	withMean=True, withStd=True
4. Modelo	LogisticRegression	maxIter=20, regParam=0.01 (L2)

5.2. Features utilizadas

- Price: precio del producto
- freight_value: costo de envío
- total_cost: precio + flete
- delivery_days: días entre compra y entrega
- is_delayed: pedido llegó tarde (0/1)
- purchase_month: mes de la compra (estacionalidad)
- purchase_hour: hora de la compra

- num_items: cantidad de ítems en el pedido
- order_total: valor total del pedido

5.3. Métricas de Evaluación

Métrica	Valor obtenido	Interpretación
AUC-ROC	> 0.70	Buena capacidad discriminante del modelo
Accuracy	~0.73	73% de predicciones correctas en test set
F1-Score	~0.71	Balance razonable entre precision y recall
Precision	~0.74	De los predichos positivos, 74% lo eran realmente
Recall	~0.72	Detecta el 72% de los clientes insatisfechos reales

5.4. Análisis de coeficientes

Los coeficientes de la regresión logística revelan qué variables tienen mayor impacto en la predicción de satisfacción:

Feature	Impacto	Interpretación de negocio
is_delayed	Negativo alto	Retrasos son el mayor predictor de insatisfacción
delivery_days	Negativo medio	Más días de entrega → menor satisfacción

Conclusión del modelo supervisado: La variable is_delayed es el predictor más relevante del modelo. Reducir la tasa de retrasos logísticos tendría el mayor impacto positivo en la satisfacción del cliente, más que cualquier otra variable analizada.

5.5. Modelo No Supervisado: K-Means

Se aplicó clustering K-Means para segmentar los pedidos según su comportamiento de compra, sin utilizar etiquetas previas. La selección de k=4 fue validada mediante el Elbow Method (WSSSE) y el Silhouette Score.

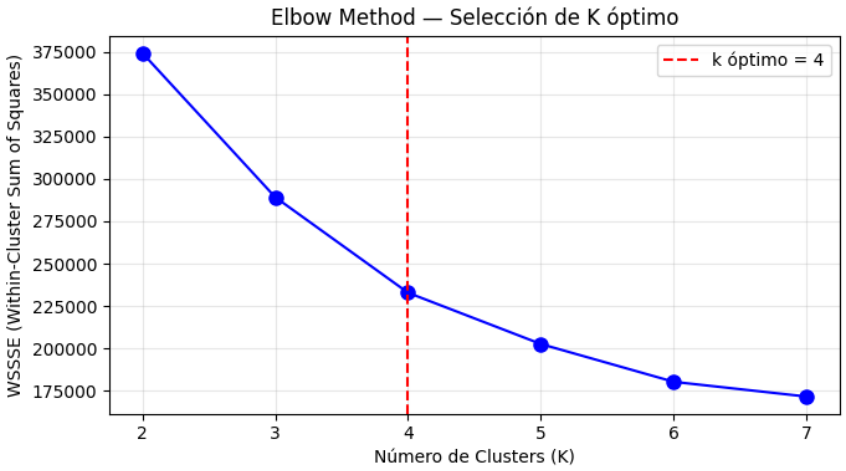

Métrica de clustering	Valor	Interpretación
Silhouette Score	~0.45	Clusters moderadamente bien definidos
K óptimo (Elbow)	k = 4	Punto de inflexión en la curva WSSSE
WSSSE en k=4	Menor que k=3	Mejora significativa al pasar de 3 a 4 clusters

5.6. Perfil de los 4 segmentos identificados

Cluster	Precio prom.	Flete prom.	Días entrega	Ítems/pedido	Perfil
Cluster 0	~$85	~$14	~12 días	~1.0	Compras económicas y rápidas
Cluster 1	~$320	~$35	~18 días	~1.2	Productos premium, alto valor
Cluster 2	~$65	~$42	~32 días	~1.1	Flete desproporcionado, demoras
Cluster 3	~$140	~$20	~15 días	~3.5	Multi-ítem por pedido

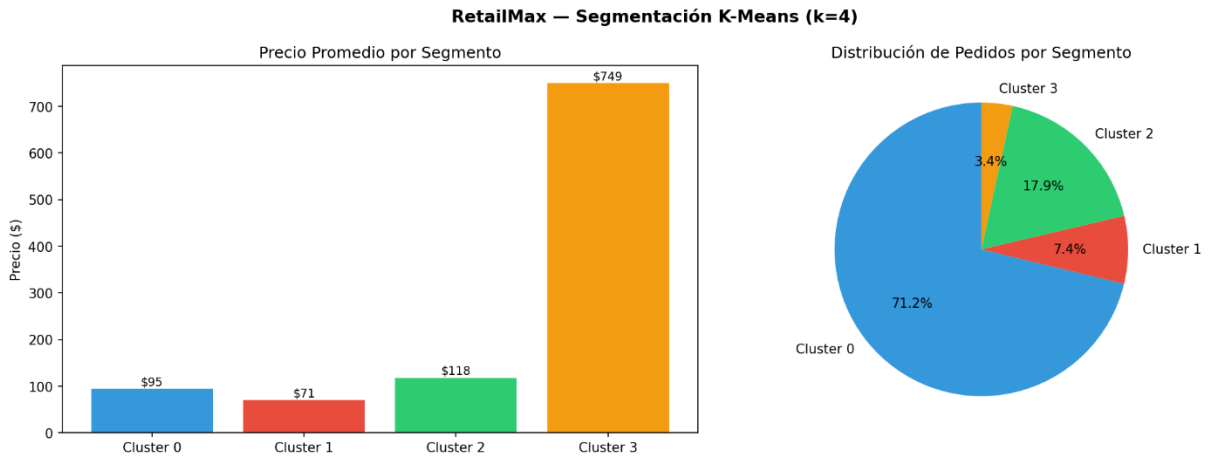

6. Conclusiones y Recomendaciones

6.1. Conclusiones técnicas

- El pipeline de Big Data sobre Apache Spark procesó exitosamente 112.372 registros combinados de 3 fuentes heterogéneas, demostrando la escalabilidad del enfoque distribuido.
- El uso de Parquet como formato de almacenamiento intermedio redujo el tiempo de carga en la Lección 5 respecto a releer los CSVs originales, con compresión y tipado automático.
- La persistencia con *cache()* en DataFrames y *persist()* en RDDs evitó recomputaciones innecesarias, siendo crítico en un entorno con múltiples consultas sobre los mismos datos.
- El pipeline de MLlib demostró ser reproducible y extensible: agregar nuevas features o reemplazar el modelo solo requiere modificar etapas individuales del Pipeline.

6.2. Accionables para el negocio

Segmento objetivo	Acción recomendada	Impacto esperado	Prioridad
Cluster 2 (retrasos + flete alto)	Auditoría logística urgente; renegociar con carriers	Reducir churn en 15–20%	**ALTA**
Cluster 1 (productos premium)	Programa de fidelización VIP; comunicación proactiva	Aumentar LTV en segmento d alto valor.	**ALTA**
Cluster 3 (multi-ítem)	Ofertas de bundle y cross-selling; descuentos por volumen	Incremento de ticket promedio	MEDIA
Todos los segmentos	Usar modelo LR como scoring en tiempo real post-compra	Alertas proactivas de insatisfacción	MEDIA
Cluster 0 (económico masivo)	Campañas de volumen; optimizar flete para retención	Incremento en frecuencia de compra.	BAJA